TRACK 2 · PRODUCTION CAPSTONE · G09

VBot Workplace: trợ lý AI văn phòng cho 2.000 người mỗi ngày

Google Cloud asia-southeast1 · Vertex AI · GKE Autopilot + gVisor · đủ 19 thành phần bắt buộc, đạt H1–H8

$11,896.84
tổng chi phí / tháng (USD, chưa VAT)

$5.95
mỗi người dùng hoạt động / tháng

$10.82
mỗi 1.000 request

TÓM TẮT

Rẻ nhờ routing model, không nhờ cắt thành phần

$11,896.84/tháng = $5,285 LLM (44%) + $4,200 nhân sự (35%) + $2,412 hạ tầng còn lại. Mọi con số lấy từ một mô hình sizing duy nhất, khớp dòng TOTAL trong báo giá.

1 · API theo cấp, không tự host GPU

Flash-Lite cho email/tài liệu, gpt-oss-120b cho code và lập kế hoạch, Gemini 3.8 Flash làm model tham chiếu và leo thang. Tiết kiệm **$21,538**/tháng so với dùng model tham chiếu cho mọi request.

2 · Một cluster, cô lập bằng gVisor

GKE Autopilot regional 3 zone chạy API, gateway, connector, policy và sandbox. Code của agent chạy trong pod gVisor không egress, 80% trên Spot Pod: sandbox chỉ **$224**/tháng.

3 · Dữ liệu tách theo người dùng

Cloud SQL HA + pgvector lọc theo ACL gốc và user_id, workspace GCS multi-region ASIA với khóa riêng, token OAuth ủy nhiệm bọc bằng khóa HSM. RTO 4 giờ, RPO 1 giờ.

Ràng buộc cứng

H1 một cloud, Vertex AI qua Private Google Access · H2 SSO OIDC/SAML + MFA, OPA, OAuth ủy nhiệm · H3 gVisor, deny egress · H4 Model Armor + xác nhận hành động ghi · H5 CMEK, DLP, audit 12 tháng · H6 p95 TTFT ≤ 3 giây, agent ≤ 10 phút · H7 multi-AZ, RTO 4h/RPO 1h · H8 cổng eval ≥ 95%, quota + ngân sách

Cơ cấu $11,896.84/tháng



GIẢ ĐỊNH VÀ ƯỚC LƯỢNG TẢI

Từ 2.000 DAU ra 1,1 triệu request và 12,3 tỷ token mỗi tháng

1. **2.000 × 25 req × 22 ngày = 1.100.000 req/tháng**
   25 req/người/ngày gồm cả hỏi lại; khớp mức REQ_PER_USER của đề
2. **Cao điểm 2,5 req/s, đỉnh 5 req/s**
   18% request/ngày rơi vào 9–10h; × 2 đỉnh theo phút; ~50 phiên streaming đồng thời
3. **11.142 token vào, 1.741 token ra / req**
   27.855 token vào/s, 4.352 token ra/s giờ cao điểm
4. **525.800 lượt sandbox/tháng**
   45 giây × 1 vCPU/2 GiB = 6.572 vCPU-giờ
5. **Lưu trữ**
   Workspace 2.000 GiB (TB 1 GB/người, quota 10 GB) · KB 300k tài liệu = 2,4M vector (9,2 GiB) · chat 12 tháng 101 GiB · 1,8M lệnh gọi connector

CẤP TÁC VỤ	TỈ LỆ	REQ/THÁNG	TOKEN VÀO	TOKEN RA	SANDBOX	LLM/THÁNG
L1 Email và hỏi đáp	52%	572.000	3.500	350	0,0	$789
L2 Tài liệu và slide	22%	242.000	9.000	2.200	0,5	$1,751
L3 Dữ liệu và code	12%	132.000	24.600	4.405	2,5	$949
L4 Agent dự án	9%	99.000	46.000	4.400	0,2	$759
L5 Thiết kế	5%	55.000	5.000	3.000	1,0	$1,037
Tổng	100%	**1.100.000**	12,26 tỷ	1,91 tỷ		**$5,285**

Token/req gộp mọi lần gọi LLM: system prompt, RAG, lịch sử, các bước agent và phần leo thang. Cache ngầm 25–60% prefix theo cấp. Chi tiết công thức ở sheet GiaDinh của báo giá.

Mạng

LB 299 GiB/tháng (80 KB/req + 5 MB file/người/ngày); egress tới người dùng ~202 GiB

Log, audit

App + GKE 40 GiB/tháng; audit ~3,1 GiB/tháng, giữ 12 tháng

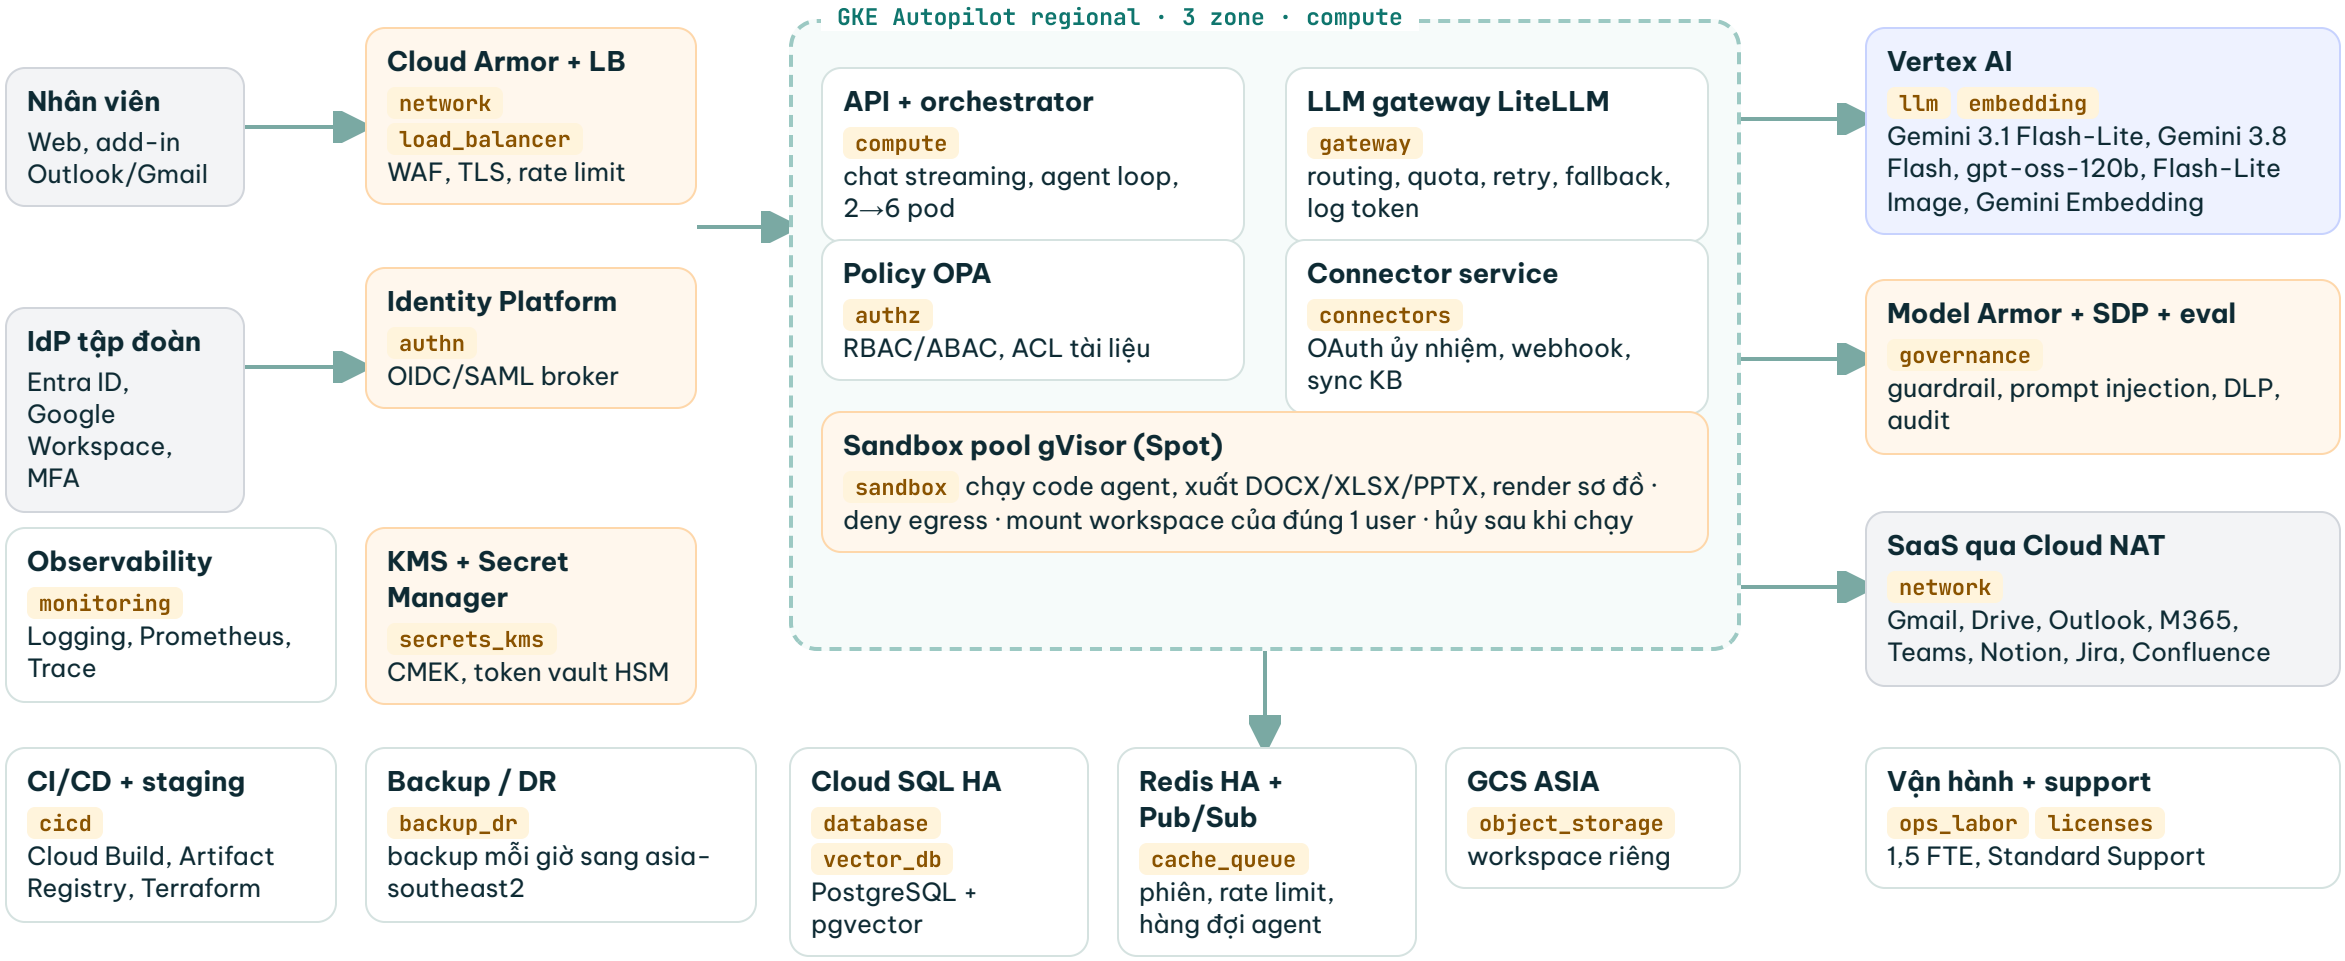
Ảnh cấp 5

40% request thiết kế cần ảnh: 22.000 ảnh 1K/tháng, quota 15 ảnh/người

KIẾN TRÚC TỔNG THỂ

Một region, ba zone, mỗi hộp là một dòng báo giá

asia-southeast1 (Singapore): gần Việt Nam, đủ dịch vụ; model gọi qua Vertex AI Global endpoint trong mạng Google.



LUỒNG MỘT REQUEST

"Tóm tắt thread này và soạn trả lời" đi qua 9 bước

1. **SSO** `authn`
   Identity Platform chuyển sang Entra ID/Google, MFA theo Conditional Access, cấp phiên 8 giờ
2. **Cloud Armor → LB → API** `load_balancer`
   WAF, rate limit theo IP; API kiểm quota user trong Redis
3. **OPA** `authz`
   vai trò + đơn vị + cấp tác vụ được phép; danh sách tool cho phiên này
4. **Connector đọc thread bằng token của chính user** `connectors`
   giải mã refresh token qua KMS, scope gmail.readonly; KB chung lọc theo ACL trong pgvector
5. **Model Armor quét prompt + nội dung email** `governance`
   đánh dấu nội dung ngoài là dữ liệu, không phải chỉ dẫn
6. **Gateway chọn model theo cấp** `gateway`
   semantic router (embedding) → Gemini 3.1 Flash-Lite; khó → Gemini 3.8 Flash
7. **Stream câu trả lời** `llm`
   Model Armor quét output; ghi token + chi phí theo user và đơn vị
8. **Hành động ghi cần xác nhận**
   gửi email, tạo ticket, xóa file: hiện bản nháp, user bấm xác nhận; DLP che PII trước khi gửi
9. **Audit + lưu lịch sử** `database`
   Cloud SQL (chat, memory theo user_id), audit log 12 tháng

Tác vụ nền cấp 3–4

API → Pub/Sub → worker agent (gpt-oss lập kế hoạch, Flex) → sandbox gVisor / connector → kết quả vào workspace → thông báo qua Chat/email. Retry 3 lần, hủy được, timeout 10 phút.

Ngân sách p95 TTFT ≤ 3 giây (H6)

auth + quota 80 ms · OPA 10 ms · connector 600 ms · pgvector 120 ms · Model Armor 200 ms · gateway 20 ms · TTFT model ~1.000 ms → **~2,0 giây**, còn 1 giây dự phòng.

MODEL VÀ ROUTING

Model tham chiếu Gemini 3.8 Flash, chỉ dùng khi model rẻ không đạt

CẤP	MODEL CHÍNH	LEO THANG	LÝ DO	GIÁ /1M TOKEN (VÀO/RA)	USD/THÁNG
1 Email, hỏi đáp	Gemini 3.1 Flash-Lite	5% → 3.8 Flash (router)	câu ngắn, tiếng Việt tốt, TTFT thấp	$0.25 / $1.50	$789
2 Tài liệu, slide	Gemini 3.1 Flash-Lite	10% → 3.8 Flash	văn bản dài; xuất file trong sandbox	$0.25 / $1.50	$1,751
3 Dữ liệu, code	gpt-oss-120b	25% thử lại kèm log lỗi; 8% → 3.8 Flash	reasoning + code mạnh, có test trong sandbox để tự kiểm	$0.09 / $0.36	$949
4 Agent dự án	gpt-oss-120b lập kế hoạch, Flash-Lite thực thi	15% planner → 3.8 Flash; 90% Flex	chạy nền, chịu được trễ Flex/Batch	Flex $0.125 / $0.75	$759
5 Thiết kế	Flash-Lite sinh HTML/SVG/Mermaid; Flash-Lite Image	—	sơ đồ, mockup render bằng code; ảnh 1K $0.0336	$0.25 / $1.50	$1,037

Đo chất lượng (H8)

Bộ test vàng 300 case mỗi cấp, chấm bằng LLM-judge (Gemini 3.8 Flash) + 10% người duyệt. Model rẻ phải đạt ≥ 95% điểm của model tham chiếu mới được bật.

Không tự host

Toàn bộ phần gpt-oss qua API chỉ $606/tháng; riêng phụ phí 2 GPU H100 trên Autopilot (HA) đã $2,107/tháng, chưa kể máy GPU. Tự host chỉ đáng xét khi phần gpt-oss tăng quá ~3,5 lần.

Giá chuẩn, không ưu đãi

Gemini 3.8 Flash tính theo giá Standard $1.50/$7.50 (áp dụng từ 01/2027), không dùng mức giá giới thiệu đến hết 2026.

LÝ DO CHỌN CÔNG NGHỆ

Mỗi lựa chọn lớn so ít nhất hai phương án, có số

QUYẾT ĐỊNH	CHỌN	PHƯƠNG ÁN LOẠI	SỐ LIỆU QUYẾT ĐỊNH
Phục vụ LLM	**API Vertex AI, routing 3 model**	Tự host gpt-oss trên H100; mọi request dùng Gemini 3.8 Flash	LLM $5,285 so với $26,823 nếu không routing; tự host ≥ $2,107 chỉ riêng phụ phí GPU
Endpoint model	**Global endpoint**	Regional asia-southeast1	Gemini 3.x và gpt-oss chưa có regional Singapore; giá non-global cao hơn 10%. Dữ liệu lưu trữ vẫn ở Singapore
Compute	**GKE Autopilot**	GKE Standard tự quản node; VM riêng cho sandbox	Trả theo pod: compute + gateway + sandbox $511; gVisor bật sẵn trên Autopilot; không phải vá node → giữ 1,5 FTE
Sandbox	**gVisor + Spot Pod**	MicroVM (Kata) cần nested virtualization; on-demand	gVisor khởi động < 200 ms (giữ TTFT); Spot rẻ hơn 70% → tiết kiệm $254/tháng
Vector DB	**pgvector trong Cloud SQL HA**	Vector Search managed riêng	2,4M vector = 9,2 GiB, chỉ thêm $9.52/tháng SSD; lọc ACL bằng SQL cùng giao dịch, không phải đồng bộ quyền sang hệ thứ hai
Workspace	**GCS multi-region ASIA**	Regional Singapore + job sao chép DR	$0.026 so với $0.020/GiB nhưng có sẵn bản sao 2 vùng (RPO ≤ 1 giờ) → không cần pipeline DR riêng
LLM gateway	**LiteLLM OSS trên GKE**	Apigee; gọi thẳng SDK	$85/tháng, có budget/quota theo user và team, fallback, API kiểu OpenAI → đổi nhà cung cấp không sửa app

CONNECTORS VÀ PHÂN QUYỀN

Agent chỉ thấy những gì chính người dùng thấy

CONNECTOR	SCOPE TỐI THIỂU (OAUTH ỦY NHIỆM)
Gmail, Calendar	gmail.readonly, gmail.compose (gửi chỉ sau khi user xác nhận), calendar.events
Drive, Docs/Sheets/Slides	drive.file + drive.readonly theo file được chọn
Outlook, OneDrive/SharePoint, Teams	Mail.ReadWrite, Files.Read, Sites.Read.All (delegated), Chat.Read
Jira, Confluence	read:jira-work, write:jira-work, read/write:confluence-content
Notion	public integration, user chọn trang chia sẻ

Không có tài khoản dịch vụ đọc toàn tập đoàn. Gửi email, tạo ticket, sửa trang luôn qua bước người dùng xác nhận.

Token vault `secrets_kms`

Refresh token mã hóa bằng DEK riêng từng user, DEK bọc bởi khóa HSM trong Cloud KMS; chỉ service account của connector có quyền decrypt, kèm AAD = user_id. Access token chỉ sống trong RAM, 60 phút.

ACL theo quyền gốc `authz`

Khi index KB chung, lưu danh sách principal của tài liệu nguồn vào từng chunk; truy vấn pgvector luôn có điều kiện principal ∈ nhóm của user (đồng bộ từ IdP). Mở tài liệu: kiểm lại bằng token của user.

RBAC/ABAC

OPA: vai trò × đơn vị × cấp tác vụ × độ nhạy dữ liệu. Ví dụ: cấp 4 chỉ cho nhóm dự án, dữ liệu "Mật" không gửi ra connector ngoài.

WORKSPACE RIÊNG VÀ SANDBOX

Agent của A không đọc được file của B, kể cả khi code bị chiếm

Workspace (H3) `object_storage` `database`

- GCS prefix **ws/<user_id>/**; app truy cập bằng signed URL 5 phút do backend cấp sau khi kiểm phiên
- Mỗi user một DEK (envelope encryption, CMEK); quota 10 GB kiểm ở API
- Chat, bộ nhớ dài hạn trong PostgreSQL với Row-Level Security theo user_id
- Kết quả tìm kiếm luôn lọc user_id + ACL trước khi xếp hạng
- Lifecycle: file tạm 30 ngày, chat 12 tháng, xóa theo yêu cầu

Sandbox gVisor `sandbox`

- runtimeClassName: gvisor trên GKE Autopilot; kernel chạy trong userspace
- NetworkPolicy deny-all egress; không tới VPC nội bộ, metadata server hay internet
- automountServiceAccountToken: false; KSA riêng không gắn quyền IAM nào
- Chỉ mount bản sao file của đúng user (sidecar tải theo job), ghi kết quả ngược qua API
- Giới hạn 1 vCPU, 2 GiB, 120 giây; pod bị hủy ngay khi xong

Code cố thoát ra node hoặc gọi metadata endpoint? Syscall bị gVisor chặn trước kernel host; gói tin tới 169.254.169.254 bị NetworkPolicy chặn; pod không có credential; node chỉ có IAM tối thiểu; sau 120 giây pod bị kill. 525.800 lượt/tháng tốn $224.

1 · Agent của A tạo job → 2 · Pub/Sub → 3 · Pod gVisor mới, Spot → 4 · Sidecar chép ws/A/ cần dùng → 5 · Chạy ≤ 120 giây → 6 · Kết quả về ws/A/, pod bị xóa

AI VÀ DATA GOVERNANCE

Email chứa lệnh ẩn "gửi toàn bộ hợp đồng ra ngoài": bị chặn ở 4 lớp

1 · Tách dữ liệu và chỉ dẫn

Nội dung connector được bọc như dữ liệu không tin cậy; system prompt cấm làm theo chỉ dẫn trong dữ liệu.

2 · Model Armor

Quét prompt injection, jailbreak, URL độc, PII cho prompt, nội dung connector và output. $432/tháng cho cả khối governance.

3 · Xác nhận hành động ghi

Gửi email, tạo ticket, xóa file luôn hiện bản nháp + người nhận cho user bấm xác nhận; tool gửi ra ngoài domain bị OPA chặn với dữ liệu "Mật".

4 · DLP + egress

Sensitive Data Protection che PII trước khi gửi; sandbox không có egress; NAT chỉ mở cho pod connector tới domain SaaS.

Data governance (H5)

- Mã hóa lúc lưu bằng CMEK (KMS), lúc truyền bằng TLS 1.2+
- Phân loại dữ liệu khi index: Công khai / Nội bộ / Mật
- Audit log 12 tháng: log bucket khóa retention + Archive có bucket lock
- Vertex AI không dùng dữ liệu khách hàng để huấn luyện; tắt data caching cho dữ liệu Mật

Cổng eval (H4, H8)

- Mọi thay đổi model hoặc prompt chạy qua Cloud Build: 6.000 case, LLM-judge Flex
- Chặn deploy nếu điểm < 95% model tham chiếu hoặc tỉ lệ vượt guardrail tăng
- Canary 5% người dùng trong 24 giờ trước khi bật toàn bộ

HA, BACKUP, DR

Mất một zone lúc 10 giờ sáng: người dùng thấy chậm khoảng 1 phút

THÀNH PHẦN	CƠ CHẾ HA	KHI 1 ZONE MẤT ĐIỆN	MẤT DỮ LIỆU
Cloud Armor + LB	Dịch vụ global, anycast	Không ảnh hưởng	—
GKE pod (API, gateway, connector)	≥ 2 replica trải 3 zone, control plane regional 99,95%	Pod còn lại nhận tải; Autopilot dựng pod mới 1–2 phút	Request đang stream bị retry
Cloud SQL	HA primary + standby khác zone	Failover tự động ~60 giây	0 (đồng bộ)
Redis	Standard tier, replica khác zone	Failover tự động	Cache/rate limit, dựng lại được
Pub/Sub, GCS ASIA, Vertex AI	Managed đa zone / đa vùng	Không ảnh hưởng; job agent tự retry	0

RPO 1 giờ

Cloud SQL backup on-demand mỗi giờ + PITR 7 ngày, lưu ở asia-southeast2. GCS multi-region sao chép mặc định ~1 giờ.

RTO 4 giờ

Mất cả region: Terraform dựng lại cluster + restore Cloud SQL ở Jakarta (~2 giờ), đổi DNS. Không giữ môi trường chờ để tiết kiệm chi phí.

Diễn tập hằng tháng

Restore backup mới nhất vào instance tạm 4 giờ, chạy smoke test, ghi thời gian thực tế. Chi phí $46.35/tháng cho backup + diễn tập.

MONITORING VÀ FINOPS

Biết chi phí theo từng người, cắt trước khi vượt ngân sách

Đo gì `monitoring`

- p95 TTFT theo cấp, thời gian hoàn thành agent
- Tỉ lệ lỗi, retry, fallback model, tỉ lệ leo thang
- Token, USD theo user, đơn vị, cấp tác vụ (tag của LiteLLM)
- Cache hit, Spot bị thu hồi, hàng đợi Pub/Sub
- Vượt guardrail, hành động ghi bị từ chối

Cảnh báo

- p95 TTFT > 2,5 giây trong 10 phút
- Lỗi 5xx > 1%; agent quá 8 phút
- Ngân sách tháng 50%, 80%, 100% (Cloud Billing budget + Pub/Sub)
- Một user dùng > 5 lần trung vị trong ngày

Quota và cách cắt

- Mỗi người: 400k token/ngày, 20 lượt agent, 15 ảnh/tháng
- Mỗi đơn vị: ngân sách USD/tháng trong gateway
- Vượt 80%: ép routing về Flash-Lite, tắt leo thang
- Vượt 100%: chỉ còn cấp 1–2, cần trưởng đơn vị duyệt

$2.64
LLM / DAU / tháng

$4.80
LLM / 1.000 request

$51
chi phí observability / tháng

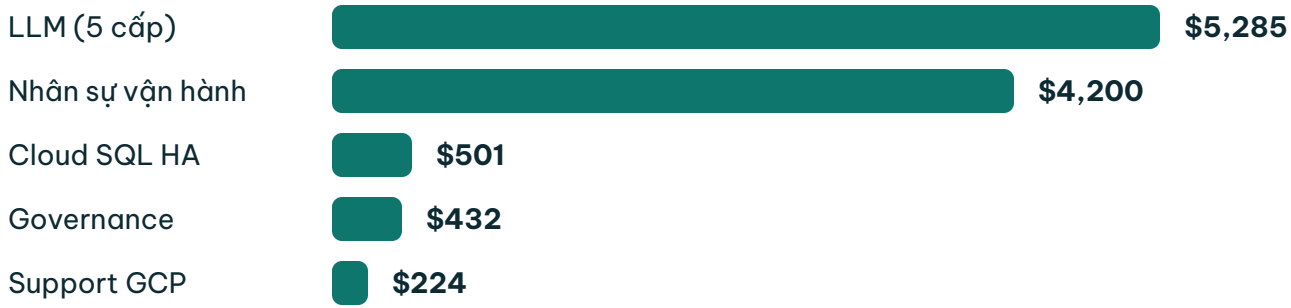
Spend log của gateway lưu trong Cloud SQL, xuất báo cáo chi phí theo đơn vị hằng tuần cho trưởng bộ phận.

CHI PHÍ

$11,896.84 mỗi tháng, $5.95 mỗi DAU

USD chưa VAT, giá niêm yết trên trang Google Cloud ngày 16/10/2026; khớp dòng TOTAL trong G09_baogia.xlsx (41 dòng, mỗi dòng có ảnh chụp bằng chứng).

5 hạng mục lớn nhất



Còn lại $1,255 cho 16 thành phần: LB, NAT, Redis, Pub/Sub, GCS, KMS, IdP, monitoring, backup, CI/CD...

Đòn bẩy tiết kiệm (so với khi không áp dụng)

Routing theo cấp (Flash-Lite, gpt-oss) thay vì mọi request chạy Gemini 3.8 Flash	**-$21,538**
Prompt caching ngầm của Gemini (prefix hệ thống, ngữ cảnh agent)	**-$847**
Flex/Batch cho agent chạy nền cấp 4 và cổng eval	**-$550**
Spot Pod cho sandbox (80% lượt chạy)	**-$254**
CUD 1 năm cho pod nền + Cloud SQL HA	**-$224**
Scale theo giờ hành chính (burst pod, staging, warm pool tắt ngoài giờ)	**-$472**

Giả định cần chất vấn: cache 25–60% prefix, leo thang 5–15%, Spot 80%, Flex 90% cho agent nền.

RỦI RO VÀ MỞ RỘNG

DAU gấp đôi, hóa đơn tăng 1,69 lần

$20,058
4.000 DAU / tháng

$5.01
mỗi DAU (giảm từ $5.95)

PHẦN	THAY ĐỔI
Tuyến tính	LLM, embedding, Model Armor, sandbox, egress, workspace
Bậc thang	Cloud SQL 4 → 8 vCPU khi > 2.500 DAU; nhân sự 1,5 → 2 FTE
Gần cố định	Cluster fee, LB, KMS, staging, CI/CD, IdP theo MAU
Đổi cách phục vụ	Khi chi phí gpt-oss > $2,107/tháng (~3,5 lần): đánh giá tự host trên GPU

RỦI RO	TÁC ĐỘNG	GIẢM THIỂU
Giá token +30%	+$1,405	routing vẫn tối ưu; quota cắt sớm
Giá token −50%	−$2,341	API càng có lợi so với tự host
Phụ thuộc Vertex AI	đổi API	gateway kiểu OpenAI, eval set dùng lại cho nhà cung cấp mới
Global endpoint không cam kết vị trí xử lý	tuân thủ	dữ liệu lưu ở SG; dữ liệu Mật chỉ dùng model có regional
Flex/Spot bị trễ hoặc thu hồi	độ trễ	quay về Standard/on-demand sau 2 phút, đã tính 10–20%
Ước lượng token sai	±30% LLM	đo thực tế 2 tuần pilot, chỉnh quota

SẴN SÀNG HỎI ĐÁP

Câu trả lời ngắn cho 6 câu hội đồng hay hỏi

A đọc được file của B?

Không: prefix + DEK riêng, RLS user_id, index lọc ACL, token connector là của A, sandbox chỉ mount file của A.

Email chứa lệnh ẩn?

Bị coi là dữ liệu, Model Armor gắn cờ, gửi ra ngoài cần user xác nhận, DLP che PII, sandbox không egress.

Thoát sandbox, gọi metadata?

gVisor chặn syscall, NetworkPolicy chặn 169.254.169.254, không SA token, giới hạn 120 giây.

DAU gấp đôi?

$20,058/tháng (×1,69); LLM tuyến tính, DB và nhân sự tăng bậc, phần nền gần cố định.

Giá token ±?

+30% → +$1,405; −50% → −$2,341. Tự host chỉ hòa vốn khi tải gấp ~3,5 lần.

Mất 1 AZ lúc 10 giờ?

SQL failover ~60 giây, pod dồn sang 2 zone còn lại, không mất dữ liệu đã commit; khớp RTO 4h, RPO 1h.

PHỤ LỤC A · KHÔNG TÍNH VÀO 15 SLIDE

Báo giá theo component (TOTAL $11,896.84)

COMPONENT	USD/THÁNG	%
llm	$5,284.72	44,4%
ops_labor	$4,200.00	35,3%
database	$501.02	4,2%
governance	$431.74	3,6%
licenses	$224.18	1,9%
sandbox	$223.55	1,9%
compute	$202.48	1,7%
cicd	$177.82	1,5%
object_storage	$96.24	0,8%
gateway	$85.23	0,7%
cache_queue	$83.55	0,7%

COMPONENT	USD/THÁNG	%
network	$70.18	0,6%
connectors	$64.74	0,5%
monitoring	$50.68	0,4%
backup_dr	$46.35	0,4%
embedding	$41.91	0,4%
authn	$36.75	0,3%
secrets_kms	$25.43	0,2%
load_balancer	$23.13	0,2%
authz	$17.62	0,1%
vector_db	$9.52	0,1%

PHỤ LỤC B · BẰNG CHỨNG GIÁ

34 ảnh chụp trang giá chính thức, ngày 16/10/2026

E01	Vertex AI (Agent Platform) pricing, bảng Gemini 3 Standard: Gemini 3.8 Flash (giá chuẩn từ 01/2027) $1.50/$0.15/$7.50, Gemini 3.1 Flash-Lite $0.25/$0.025/$1.50, cột Global
E02	GKE pricing, Singapore: Autopilot vCPU $0.0549, RAM $0.0060729; Flexible CUD 1 năm; Spot
E03	Cloud SQL for PostgreSQL pricing, Singapore: vCPU/RAM/HA, SSD, backup, CUD 1 năm
E04	Memorystore for Redis pricing, Singapore: Standard tier M1
E05	Cloud Storage pricing, Asia (multi-region): Standard $0.026/GiB-tháng
E06	Network pricing, Singapore: Cloud Load Balancing 5 forwarding rule đầu $0.028/giờ, data processed $0.009/GiB
E07	Cloud NAT pricing: gateway theo số VM, IP, data processed
E08	Cloud Armor pricing: Standard policy, rule, request
E09	Cloud KMS pricing: key version SOFTWARE/HSM, cryptographic operations
E10	Secret Manager pricing: active secret version, access operations
E11	Identity Platform pricing: Tier 2 providers OIDC/SAML $0.015/MAU
E12	Google Cloud Observability pricing: Logging storage $0.50/GiB, retention $0.01/GiB-tháng
E13	Pub/Sub pricing: throughput $40/TiB
E14	Security Command Center pricing, mục Model Armor standalone $0.10/1M tokens
E15	Sensitive Data Protection (DLP) pricing: content inspection $3/GB
E16	Artifact Registry pricing: storage $0.10/GiB-tháng
E17	Cloud Build pricing: e2-standard-2 $0.006/phút
E18	Google Cloud Customer Care: Standard Support 3% chi phí cloud (tối thiểu $29)
E19	Vertex AI locations, tab Global: Gemini 3.8 Flash, Gemini 3.1 Flash-Lite, Gemini 3.1 Flash-Lite Image có ở Global endpoint
E20	GKE Sandbox (gVisor) cho Autopilot và Standard: cô lập code không tin cậy
E21	Vertex AI pricing, bảng OpenAI models: gpt-oss-120b $0.09 in / $0.36 out mỗi 1M token
E22	Vertex AI pricing, bảng image: Gemini 3.1 Flash-Lite Image, image output $30/1M token (1120 token/ảnh 1K)
E23	Vertex AI pricing, bảng Embedding: Gemini Embedding $0.00015 / 1.000 token online
E24	Vertex AI pricing, tab Flex/Batch: Gemini 3.8 Flash $0.75/$3.75, Gemini 3.1 Flash-Lite $0.125/$0.75
E25	GKE pricing: cluster management fee $0.10 / cluster / giờ
E26	Cloud SQL pricing, Singapore, HA Storage: SSD $0.000652055/GiB-h, Backups (used) $0.000153425/GiB-h
E27	Cloud Storage pricing: inter-region replication, Asia (multi-region) $0.08/GiB
E28	Cloud Storage pricing: Class A/B operations cho bucket dual-region/multi-region
E29	Cloud Storage pricing, Singapore: Archive storage $0.0015/GiB-tháng
E30	Network pricing, Singapore: internet egress Premium tới Asia $0.12/GiB (0-1 TiB)
E31	Network pricing: data transfer giữa các zone trong cùng region $0.01/GiB
E32	Observability pricing: Managed Service for Prometheus $0.06/triệu sample
E33	Observability pricing: Cloud Trace $0.20/triệu span
E34	Cloud SQL pricing, Singapore, Storage (zonal, dùng cho staging): SSD $0.000326027/GiB-h